



華東師範大學

East China Normal University

本科生毕业论文

基于主题信息增强的客服对话摘要研究

Customer Service Summarization With
Topic Information Augmentation

姓 名: 楼城灿

学 号: 10185102233

学 院: 计算机科学与技术学院

专 业: 计算机科学与技术

指导教师: 杨燕

职 称: 副教授

2022 年 5 月

目录

摘要	i
ABSTRACT	ii
1、 绪论	1
1.1 研究背景	1
1.2 相关工作	3
1.3 本文主要研究工作	5
1.4 本文组织结构	6
2、 相关基础	7
2.1 Transformer	7
2.2 预训练语言模型	9
2.3 Prompt	10
2.4 本章小结	11
3、 主题信息增强的客服对话摘要模型	12
3.1 研究动机	12
3.2 模型概览	13
3.3 对话抽取模块	14
3.4 摘要生成模块	16
3.5 主题信息增强模块	17
3.5.1 Prompt 提取主题信息模块	17
3.5.2 主题信息融合注意力机制	18
3.6 模型训练	19
3.7 伪代码展示	21
3.8 本章小结	21
4、 模型训练与实验评价	22
4.1 数据集	22
4.2 模型设置	23

4.3	实验结果及其分析	23
4.3.1	评价指标	23
4.3.2	基线模型介绍	24
4.3.3	实验结果展示分析	24
4.4	案例分析	27
4.5	本章小结	28
5、	总结与展望	30
5.1	工作总结	30
5.2	未来工作	30
	参考文献	32
	致谢	35

基于主题信息增强的客服对话摘要研究

摘要：

近年来随着深度学习技术与自然语言处理技术的不断发展，智能客服、文本摘要等应用正逐步走入人们的生活当中。客服对话摘要以客服与客户之间的对话作为摘要材料的文本摘要任务，通常应用于客户服务系统中，近几年以来得到了学术界与工业界的广泛关注。对话摘要通过自动构建对话摘要来提高整体服务效率，帮助客服在后续服务当中快速获取客户所需信息，从而避免了无用信息的重复读取，有效减少人力耗费。

传统的文本摘要包含抽取与概要生成两种方法，然而将文档文本摘要方法直接应用对话摘要当中的效果并不理想，其原因传统的文本摘要对角色信息不做区分，生成的摘要并不能很好的把握住对话者的角色信息。此前，有学者提出将主题建模信息加入到摘要模型当中，使用主题信息来辅助对话摘要生成。然而，要获取主题模型信息通常依赖于当前训练语料，因此存在领域强关联性的问题，没有很好的泛化性；并且该模型所生成的摘要语句时常会丢失关键信息，导致摘要信息缺失。基于上述背景，本文主要的工作包括：

(1) 设计了基于 Prompt 的多角色主题信息增强客服对话摘要模型 P-TDS(Prompt-based Topic-augmented Dialogue Summarizer)，该模型使用先抽取后摘要生成的方式，并利用 Prompt 所提取出的主题信息进行分角色的信息增强。提升了模型的泛化性的同时，还把握住了对话当中的角色信息。该模型主要分为三个模块：首先是对话抽取模块，该模块以对话轮次为单位，使用指针网络对关键的对话轮次进行抽取；其次是概要生成模块，该模块基于 Transformers 的编码-解码结构，对抽取拼接后的语句进行摘要生成；最后是基于 Prompt 的主题信息增强模块，该模块使用 Prompt 分别提取出整体、客户以及客服这三类对话各自的主体信息，并将主题信息嵌入到抽取模块与摘要生成模块的解码层当中，按当前语句的角色信息进行分别指导。

(2) 在模型训练中使用并改进了强化学习算法，联系起对话抽取模块与概要生成模块，提升了对话抽取模块的执行效果，在一定程度上提高了关键语句的抽取率，进而减少所生成摘要的信息丢失。最终在 CSDS 数据集上的实验结果证实了本文模型的有效性。

关键词：客服对话摘要, Prompt, 主题信息增强, 抽取与概要, 强化学习

Customer Service Summarization With Topic Information Augmentation

Abstract:

In recent years, with the continuous development of deep learning technology and natural language processing technology, applications such as intelligent customer service and text summarization are gradually entering people's life. The text summary task, which takes the dialogue between customer service and customers as the summary material, is usually used in the customer service system, and has attracted extensive attention in academia and industry in recent years. Dialogue summary improves the overall service efficiency by automatically constructing dialogue summary, and helps customer service quickly obtain the information required by customers in follow-up services, so as to avoid repeated reading of useless information and effectively reduce labor consumption.

The traditional text summary includes two methods: extraction and abstraction. However, the effect of applying the document text summary method directly to the dialogue summary is not ideal. The reason is that the traditional text summary does not distinguish the role information, and the generated summary can not grasp the role information of the interlocutor well. Previously, some scholars proposed to add topic modeling information to the summary model and use topic information to assist in the generation of dialogue summary. However, the acquisition of topic model information usually depends on the current training corpus, so there is a problem of strong domain relevance and no good generalization; And the summary statements generated by the model often lose key information, resulting in the loss of summary information. Based on the above background, the main work of this paper includes:

(1) A multi role topic enhanced customer service dialogue summary model P-TDS (prompt based topic augmented dialogue summarizer) is designed. The model uses the method of extracting first and then generating summary, and uses the topic information extracted by prompt for role-based information enhancement. It not only improves the generalization of the model, but also grasps the role information in the dialogue. The model is mainly divided into three modules: the first is the dialogue extraction module, which uses the pointer network to extract the key dialogue rounds in the unit of dialogue rounds; The second is the summary generation module, which generates the summary of the extracted and spliced statements based on the encoding decoding structure of transformers; Finally, the topic information enhancement module based on prompt, which uses prompt to extract the topic information of the whole, customer and customer service respectively, and embeds the topic information into the decoding layer of the extraction module and the summary genera-

tion module to guide respectively according to the angle information of the current sentence.

(2) The reinforcement learning algorithm is used and improved in the model training, which connects the dialogue extraction module and the summary generation module, improves the execution effect of the dialogue extraction module, improves the extraction rate of key sentences to a certain extent, and then reduces the information loss of the generated summary. Finally, the experimental results on CSDs data set confirm the effectiveness of this model.

Keywords: Customer Service Summarization, Prompt, Topic Information Enhancement, Extraction and Abstraction, Reinforcement Learning

1、绪论

判断计算机是否理解自然语言有四条标准，分别为：文摘、释义、问答以及复述^[1]。能够对所给的语言材料进行摘要便是计算机理解自然语言的标准之一。客服对话摘要作为文档摘要的一个任务分支在近几年因为其商业价值与研究价值引起了大量的研究学者的关注。客服对话摘要基于客服对话数据集，其目的是从客服与客户的对话中提取最重要的信息并重新组织语言，并将重要的信息汇聚到一个更短的段落中，这可以帮助人们快速捕捉客服对话当中较为重要的信息，而无需回顾复杂的对话背景，以及省略一些多余的语句^[2]。在本章当中，我们将会介绍客服对话摘要的研究背景，列举出客服对话摘要的研究现状，并指出当前研究存在的问题，然后具体明确本文研究的问题，以及提出本文的研究框架以及具体的工作内容，最后给出后续文章的内容组织安排。

1.1 研究背景

近年来，随着世界范围内大量研究者对人工智能领域进行了深入研究，人工智能与深度学习技术得到了蓬勃的发展，其中自然语言处理领域相关的研究也获得了长足的进步。文本摘要便是其中最具有应用价值的方向之一。同时，随着社会的发展和通讯技术的进步，各式各样的对话数据日益增多。对话摘要虽然是文本摘要的一个分支，但是与一般的文档摘要不同，对话摘要主要依托于各式各样的对话。根据对话发生的场景不同，可以对其进行基本的分类，比如有会议、邮件、闲聊、讨论、辩论、客服等等，不同形式的对话数据有着各自的特点。对话摘要的目的是将对话中最重要的信息提炼成相对较短的段落，帮助人们快速在不回顾复杂对话背景的情况下捕捉多参与者对话当中的重点，同时也可以借助对话摘要生成的信息来更好的辅助下游任务^[3]。因此，如何对不同场景下的对话数据进行清洗摘要处理，并将对话当中的信息进行精炼，进而应用到现实生产场景当中便成了一个亟待解决的问题。

而客服对话摘要则是应用于企业的客服系统当中，如图 1-1 所示，客服对话摘要基于客服与客户之间的对话信息来提炼出对话当中的重要信息。在许多企业中，一旦完成了处理客户请求，它就需要为此人工创建一个简短的对话摘要。在一个活跃的客户服务体系中，客户和客服之间存在传递重要信息的大规模对话。摘要可以辅助客服来快速了

客服对话	
(0)	【客户】 咨询订单号:[订单编号]商品ID:1281671
(1)	【客户】 商品信息咨询
(2)	【客服】 有什么问题我可以帮您处理或解决呢?
(3)	【客户】 我 购买三箱纯牛奶, 怎么只送了二箱, 他说有一箱损坏
(4)	【客服】 还请您稍等, 正在为您查询~
(5)	【客服】 您那边配送会给您赔付的呢
(6)	【客户】 问题是我要三箱牛奶,
(7)	【客户】 补发?
(8)	【客服】 这边会赔付您相应的价格然后您重新下单就好了哦
(9)	【客户】 怎么赔付?
(10)	【客服】 这个是由 配送去给您赔偿的
(11)	【客户】 看后续处理如何, 再说
(12)	【客户】 再见
(13)	【客服】 请问还有其他还可以帮到您的吗?
对话摘要	
用户表示 购买了三箱纯牛奶,但由于一箱损坏只送了二箱, 询问是否应该补发。 客服回答 这边会赔付用户相应的价格然后用户重新下单。 用户询问 怎么赔付。 客服表示 由配送去给用户赔偿。	

图 1-1 客服对话摘要样例

解用户问题, 提供解决方案, 以及获取用户反馈, 同时可以辅助企业调整服务策略, 也可以为质检人员评估客服的服务质量提供依据。客服对话摘要能够帮助企业部门在后续的服务当中快速获取关键信息并提供对应解决方案, 避免了重复读取无关信息, 有助于帮助企业减少人力成本, 同时也有助于提升客服质量, 规范客服行为。更重要的是, 糟糕的人工摘要会导致对用户的问题做出错误的决定, 而自动生成摘要可以帮助保证所有的摘要具有相同的标准, 从而有别于人工操作, 可以更精确的处理服务需求, 因此对话摘要任务在近几年得到了工业界和学术界的广泛关注。

当前, 在文本摘要领域的传统工作主要集中于无角色信息的摘要, 如对新闻和科学论文进行摘要^[4]。随着神经网络模型的发展, 特别是引入复杂的预训练语言模型, 文档摘要也因此获得了长足的进步。这些模型显著地推进了文本摘要的性能与效果。然而, 虽然文档摘要取得了一定程度上的成功, 但是这些方法并不能很好地应用到对话摘要当中。其中主要有两个原因, 首先, 对话的结构不同于文档, 对话的关键信息往往是分散的, 常常出现不同参与者的多个话语中, 导致整体对话信息密度较低。其次, 对话中包含两个及以上的参与者, 其中存在着固有的主题漂移、频繁的共同引用、不同的交互信号和领域术语等难点。上述两个特点使得对话摘要成为一项具有挑战性的任务。

此外,针对客服对话摘要,所摘取生成的文本应该是合乎逻辑并且符合对话的顺序,即对话中的摘要必须以可读的顺序组织起来。在客户服务中的对话当中,摘要通常首先描述用户的问题,然后是解决方案,最后是用户的反馈,最终摘要所展现的效果一般为客服与客户的一问一答形式。虽然对话在逻辑上有可能是混乱的,但人类主体需要以一种逻辑和可理解的方式写出总结。对话摘要模型应该顺应逻辑生成总结。第二,摘要应该是不可分割的,即摘要应该涵盖了对话中的所有重要事实,丢失的事实会导致对用户问题的误判。第三,摘要应确保其对关键事实的正确性,某些句子有可能有相同的语义,但是却具有相反的事实。最后,对于复杂的对话,摘要总结可能会很长,模型如何去除不重要的词句,如何生成摘要也是一个挑战。

近几年来, Prompt 作为一个新兴研究方向得到了自然语言处理学者的深入研究, Prompt 与预训练模型相结合,提升了预训练模型的使用效率^[5]。并且 Prompt 技术通过设计模板的方式来为预训练模型提供提示,从而更好的使用原模型当中未被发掘的知识。Prompt 已被运用在文本摘要^[6]、文本分类^[7]和主题语义理解等任务当中,通过设计合适的模板, Prompt 能够获取更多的隐含知识信息。

基于以上背景,我们提出了主题信息增强的客服对话摘要模型,通过使用 Prompt 抓取并使用主题信息来引导摘要生成,在利用角色信息的同时来实现更完善流畅的对话摘要,并保留对话摘要的逻辑性,进而帮助企业客服更好的获取对话当中的重要信息,最终给用户提供更精确、更优质的服务。

1.2 相关工作

处理摘要任务主要有两种处理方法,分别为提取法 (Extraction) 和概要生成法 (Abstraction)。其中提取法直接选择原文本中的句子或词语作为摘要,通过引用原文本的词与句,能够使得摘要表现的更加准确和可靠^[8]。而概要生成法则采用深度学习技术(主要使用 seq-to-seq 模型)像人类一样解释和缩短原始文档,由于该算法可以自行生成代表源文本中重要信息的短语和句子,因此概要生成法帮助克服了抽取技术容易产生语法错误的缺点,从而在一定程度上相较于提取法提高了摘要的简洁性和流畅性^[9]。

基于上述的两种方法,对话摘要的一种简单方法是将对话的所有语句全部连接在一起当作一篇文档来进行摘要。然而,与文档摘要不同的是,对话摘要应该考虑话语的说话者,并且对话通常具有随意性,包含一些嘈杂无用的语句,因此,核心信息在对话中

会被稀释。先前的对话摘要工作通常集中于设置关键点来总结对话，以此来保持一个完整的对话流^[10]，研究者采用特征工程^[11]和模板选择^[12]进行对话总结。但是这些模型需要人们手动设计特性或模板。特性和模板的有限数量阻碍了它们的可扩展性。在客户服务对话中，参与的角色是稳定的：客户倾向于提出问题，客服则需要提供解决方案。Liu 等人^[13]提出从对话中推断出关键点序列，采用了一个从粗到细的生成框架，它首先生成一系列的关键词（主题）来指示对话的逻辑，然后根据这一些关键词来实现详细总结。例如，一个关键词序列可以是问题 → 解决方案 → 用户批准 → 结束，这清楚地显示了对话当中的逻辑，从而可以帮助生成更有逻辑性更完备的摘要。同时 Li 等人^[14]也提出了将对话根据主题来分割成块来分别生成摘要的方法。Shang 等人^[15]将对话根据语义信息进行联合分组，然后通过对各组的分别总结来生成最终摘要。与上述方法不同的是，Pan 等人^[16]首次尝试为整个对话生成一个高度抽象的摘要，并使用基于 Transformer 的方法生成一个简明的事件以及对象描述，相比之下，在这项工作中，对话摘要更加突出特定角色的内容，这要求系统进一步关注角色信息。

由于对话摘要标准数据集的欠缺，对话摘要工作引入了无监督学习的方法^[17]，在缺乏标记数据的情况下，可以选择无监督的方法进行学习，Zou 等人^[18]提出了一种称为 RankAE 的无监督框架来缓解数据不足的问题，在该框架中，首先根据中心性和多样性同时选择主题话语，然后使用去噪自动编码器生成最终摘要。客户服务也是一种面向任务的对话，它包含信息实体，涵盖不同的领域，涉及两种不同类型的参与者。为了整合各种信息，Yuan 和 Yu^[19]提出了支架指针网络，利用说话人角色、语义槽和对话域三种信息以第三人的观点产生总结。由于客户服务的参与者扮演着不同的角色，Zhang 等人^[20]提出了一个基于变分自动编码器的无监督框架，分别为客户和客服生成摘要。

在文本摘要的方法当中，已有将主题信息进行融入摘要的方法研究。先前，神经主题模型^[21]被引入来推断文档的潜在表示，它利用深度神经网络作为学习主题分布的近似器用以生成主题模型。一些模型已经使用了这些主题信息来推进文本摘要任务，如 Wang 等人^[22]和 Narayan 等人^[9]使用 LDA 来推断主题嵌入，并设计一个联合注意机制来整合主题信息。Fu 等人^[23]将主题推理模块与摘要模型合并，而不是简单地使用预先训练好的主题模型。Zou 等人^[24]提出融合了神经主题模型的客服对话摘要模型，将主题信息加入到了客服对话摘要任务当中。

除此之外，近些年以来 Prompt 的发展逐渐受到了研究者的注意，通过使用 Prompt

构建模板的方式可以挖掘出预训练模型当中未被使用的知识，Prompt 在多个自然语言处理领域的应用显示了它的潜力。Cao 等人^[25]通过使用 Prompt 来辅助引导文本摘要生成。Liu 等人^[26]提出使用 Prompt 与注意力机制相融合从而辅助下游任务，通过 Prompt 提供了外部提示来提醒模型应该关注哪一部分的信息。

综上所述，客服对话摘要研究虽然取得了一定的进展，但目前该领域中仍存在着不少问题亟须研究。现有文本摘要框架并不能很好的用于对话的摘要，原因为会丢失基本的对话角色信息；而单纯的抽取式或概要生成式摘要模型执行效果并不佳，容易造成关键信息的丢失。对于 Zou 等人提出的神经主题模型指导的客服对话摘要模型，其根本上是融合主题模型所产生的信息，该模型的主题模型信息通常依赖于当前训练语料，因此该模型的泛化性较差，而我们认为使用 Prompt 也可以获取到当前的主题信息，可以对主题模型进行替代并融入到摘要模型当中，使得模型更具有泛化性。同时，为了应对生成的摘要在信息完整性上表现不佳的问题，我们认为需要在抽取关键句的步骤上提升效果。

1.3 本文主要研究工作

通过上述对于国内外客服对话文本摘要的相关研究的调研与分析，我们认识到了客服对话摘要的巨大潜力，同时，我们也总结出现阶段客服对话摘要遇到的一些问题以及研究者新提出的一些想法。本研究的主要目标是使用 CSDS 中文客服对话数据集，在已有的基础文本摘要模型上进行改进，在提升模型泛化性的同时，让生成的摘要更具有信息完整性。本文的具体研究工作可概括为以下两点：

(1) 设计了基于 Prompt 的多角色主题信息增强客服对话摘要模型 P-TDS(Prompt-based Topic-augmented Dialogue Summarizer)，该模型使用先抽取后摘要生成的方式，并利用 Prompt 所提取出的主题信息进行分角色的信息增强。提升了模型的泛化性的同时，还把握住了对话当中的角色信息。该模型主要分为三个模块：首先是对话抽取模块，该模块以对话轮次为单位，使用指针网络对关键的对话轮次进行抽取；其次是概要生成模块，该模块基于 Transformers 的编码-解码结构，对抽取拼接后的语句进行摘要生成；最后是基于 Prompt 的主题信息增强模块，该模块使用 Prompt 分别提取出整体、客户以及客服这三类对话各自的主体信息，并将主题信息嵌入到抽取模块与摘要生成模块的解码层当中，按当前语句的角色信息进行分别指导。

(2) 在模型训练中使用并改进了强化学习算法, 联系起对话抽取模块与概要生成模块, 提升了对话抽取模块的执行效果, 在一定程度上提高了关键语句的抽取率, 进而减少所生成摘要的信息丢失。最终在 CSDS 数据集上的实验结果证实了本文模型的有效性。

1.4 本文组织结构

第一章为绪论, 介绍客服对话摘要的研究背景, 说明客服对话摘要的研究意义以及其广泛应用场景, 然后介绍过去研究中关于客服对话摘要的方法以及之后更新的模型, 中间提出了它们各自存在的问题及挑战, 最后提出了本文的研究目标。

第二章为相关知识与技术研究, 围绕本文所开展的研究, 详细阐述了其中涉及到的知识和技术。首先介绍了指针网络的相关知识, 然后介绍了当前自然语言处理研究中常用的预训练语言模型, 最后介绍了 prompt 的相关知识及其解决的问题, 上述的这三个知识点是和本文密切相关的。

第三章为本文所提出的主题信息增强的客服对话摘要模型, 在这一章中, 我们详细阐述了这个模型的架构以及具体的实现方式。

第四章为实验与评价部分, 该章具体讲述了整体训练细节, 以及后续的实验, 最后通过实验结果的对比和分析来得出结论。

第五章为总结与展望, 在最后这个章节中, 我们首先对本文的工作内容进行了总结, 并提出当前研究当中还存在的各种不足, 最后提出了我们对该研究方向未来发展的展望。

2、相关基础

2.1 Transformer

Transformer 模型由 Google 于 2017 年发表^[27]，其主要解决序列到序列 (Seq2Seq) 相关的问题，该模型使用注意力机制来替代了 LSTM 模型，抛弃了先前传统的 CNN 和 RNN 的固有模式，结果不仅减少计算量，提升并行效率，同时还取得了更好的任务结果。

Transformer 的总体框架如图 2-1 所示，该模型基于编码-解码器结构，图 2-1 的左半部分为 Encoder 当中的一层，作为编码器，而右半部分则代表的是 Decoder 部分当中的一层，作为解码器，在原模型架构当中，编码器和解码器分别各使用了六层。

使用该模型时，首先需要将输入的序列经过词嵌入 (Input Embedding) 层，然后与位置编码 (Positional Encoding) 相加之后，再输入到编码器当中。在编码层当中，模型首先使用了多头注意力机制，之后再经过全连接前馈神经网络 (Feed Forward)，此外，作者还加入了残差机制以及层标准化来帮助训练。其次是解码层，该模块通过接收编码层的信息，分别使用两次输入不同的多头注意力机制以及一次前馈神经网络，最终输出到 Softmax 层当中得到结果。下文将介绍 Transformer 模型中采用的注意力机制。

Transformer 模型的主体思想是注意力机制，作者将该模型所使用的基础注意力取名为点乘注意力 (Scaled Dot-Product Attention)，该模块的具体结构如图 2-2 所示。首先对于输入，先经过线性变换得到 Q (query)，K (key) 以及 V (value) 这三个值。具体的做法为。具体的计算方法为首先用 Q 去对每个 K 做矩阵乘法，在这里意为 Attention，此处存在的一个问题便是当 Q 和 K 的向量维度很大的时候，那么 Q 和 K 进行矩阵乘法得到的数值就会相应的变大，因此得到的矩阵乘法结果需要除以 Q 和 K 的向量维度来作为平衡，之后再经过 Softmax 层得到对 V 的权重。最后可以给出注意力计算公式为：

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V \quad (2.1)$$

Transformer 模型在基础注意力机制之上，提出了多头注意力机制 (Multi-Head Attention)，多头机制通过形成多个参数子空间，由此来对不同方面的信息进行建模，它是将多个点乘注意力进行拼接得到，且可以根据需要设置超参数头部数量。




图 2-1 Transformer 模型结构图




图 2-2 基础注意力机制结构

2.2 预训练语言模型

近几年以来,随着深度学习和大数据的迅猛发展以及电脑算力的提升,预训练语言模型逐渐出现在人们的视野当中,进而把自然语言处理带入了一个全新的阶段,预训练语言模型所取得的成果得到了学术界与工业界的广泛关注。预训练语言模型通过对大量数据的协同训练以及少量的微调便可以达到较好的效果,从而不再需要大量的人工调参。

不同于早期的词袋模型,词袋模型虽然能够方便计算机快速处理数据,却无法衡量单词间的语义相似度,而预训练模型则包含了语料当中的潜在信息。预训练语言模型主要有以下几个发展阶段,首先是 Mikolov 等人^[28]于 2013 年提出了 Word2Vec 语言模型,该方法主要基于分布式表示的方法被提出,使得判断语义之间的相似度成为可能,然后是 2018 年 Peters 等人^[29]所提出的 ELMO 模型,该模型打破了 Word2Vec 模型当中的固定词向量概念,不同于以往的一个词对应一个向量,在 ELMO 模型当中,预训练完成的模型不再只是向量对应关系,而是包含整个训练好的模型。在具体使用时,模型会主动根据输入内容的上下文来推断每个词对应的词向量。这样便可以使得词拥有多种含义,而不是一个静态固定的值,从而可以结合前后语境对多义词进行理解。之后便是 Devlin 等人^[30]提出的 BERT 模型, BERT 使用 Transformer 架构的编码层,通过引入 Mask 机制进行训练预测,具体方法为随机地选一些需要进行预测的词,然后用特殊的符号 [MASK] 来代替这些词,之后让模型便会根据所给的标签去具体学习这些地方该填的词。

其中根据原理不同,预训练语言模型大体可以分为以下两类:

其中第一类为自回归的语言模型,它通过结合给定的上下文信息,来对当前的词进行预测,其中训练过程要求下述进行似然估计最大化,即满足:

$$\max_{\theta} \log p_{\theta}(x) = \sum_{t=1}^T \log p_{\theta}(x_t | x_{<t}) \quad (2.2)$$

该类预训练模型的代表模型有 GPT3,ELMO 等,该类模型优点在于它是对整体文本序列的联合概率密度进行估计,在进行生成任务时是从左向右按照序列生成,因此适用与自然语言生成任务,这和自回归语言模型的模式相一致,而其缺点在于由于该模型是按序列生成的,它只能利用单向序列的信息,而不能同时利用双向的前后文信息。即使 ELMO 这种模型采用了双向的方法,但是它的效果并不好。

第二类则是自编码语言模型，代表模型有 BERT 系列。BERT 预训练模型的优点在于它可以直接使用上下文的信息来生成双向的特征表示，而缺点是在训练时候，引入的 Mask 标记会导致预训练阶段和微调阶段的不一致问题，它训练的目标就是要使得预测的概率最大化，即为：

$$\max_{\theta} \log p_{\theta}(\bar{x} | \hat{x}) \approx \sum_{t=1}^T m_t \log p_{\theta}(x_t | \hat{x}) \quad (2.3)$$

预训练语言模型为自然语言处理带来了巨大的进展。当前有越来越多的预训练语言模型出现，成为现今自然语言处理领域最关键的技术之一。

2.3 Prompt

近几年以来，有关于预训练语言模型研究的发展愈加迅速，在一般的应用场景当中总是将预训练语言模型应用到下游任务上，根据具体的下游任务对于预训练语言模型进行微调。但是随着语言模型的体积不断增大，在实际应用当中，所需要的硬件要求以及实际代价也相应的增加。因此，研究者想探索出一个更小巧普适的方法来解决这个问题，Prompt 便是沿着这个方向的尝试之一。

Prompt 在设计之初是学者们为了获取下游任务信息而设计出来的一种模板或者是输入形式，研究者的初衷是希望 Prompt 能够帮助预训练语言模型重新回忆起自己在预训练时训练学习到的东西。Prompt 可以使用函数表现为以下形式：

$$x' = f_{\text{prompt}}(x) \quad (2.4)$$

本质上是对于输入的文本 x ，通过函数变换得到所需要的下游任务信息。

使用 Prompt 将把下游的具体任务重新调整为类似于预训练语言模型任务的形式。比如说，在 BERT 模型的预训练模型当中，使用 Mask 的方法来进行随机替换，并在训练当中尝试填上被遮住的字符。因此，在文本分类的任务当中，Prompt 可以设计成，“[X] Overall, it was a [Z] movie”，这样的形式，其中 [X] 指代原文本，而 [Z] 代表的则是预期填入的字符，让预训练模型自行填写，然后通过读取利用 [Z] 中的值，可以进一步转化为文本分类的标签。这样，就可以通过选取合适的 Prompt，来控制模型的预测输出，进而可以使用完全无监督训练的预训练语言模型来解决各自不同的下游任务，也可以挖掘出隐含在预训练模型的知识信息来对具体的任务进行信息引导与增强。

2.4 本章小结

在本章当中，我们介绍了与文本摘要技术相关的技术知识以及概念。首先介绍了 Transformer 模型，在给出了具体的模型之后，我们着重介绍了该模型当中所用到的注意力机制；其次介绍了目前自然语言应用广泛的预训练语言模型的知识点，并对模型类别进行了简单的阐述；最后介绍了有关于 Prompt 的相关知识，以及其具体应用场景。

3、主题信息增强的客服对话摘要模型

3.1 研究动机

客服对话摘要任务近几年以来得到了学术界与工业界的广泛关注。传统的文本摘要通常使用提取与概要生成这两种方法，但是将文档文本摘要方法直接应用对话摘要当中的效果并不理想，其原因为传统的文本摘要对角色信息不做区分，生成的摘要并不能很好的把握住对话者的角色信息，并且单纯的使用提取法或摘要生成法的效果并不好。因此，本文考虑将这两种方法结合在一起，通过先提取后概要生成的方式进行摘要，这样所生成的较为符合客服客户的对话逻辑。

此前，Zou 等人^[24]提出将主题建模信息加入到摘要模型当中，使用主题信息来辅助对话摘要生成。然而，要获取主题模型信息通常依赖于当前训练语料，因此存在领域强关联性的问题，没有很好的泛化性；并且该模型所生成的摘要语句时常会丢失关键信息，导致摘要信息缺失。因此本尝试使用 Prompt 来分角色地提取出对话当中的隐含主题信息，该方法没有进行额外的训练，而是直接进行提取应用，在一定程度上提升了泛化性。因此，本文设计了基于 Prompt 的多角色主题信息增强客服对话摘要模型 P-TDS，该模型使用先抽取后摘要生成的方式，并利用 Prompt 所提取出的主题信息进行分角色的信息增强。提升了模型的泛化性的同时，还把握住了对话当中的角色信息。该模型主要分为三个模块：首先是对话抽取模块，该模块以对话轮次为单位，使用指针络对关键的对话轮次进行抽取；其次是概要生成模块，该模块基于 Transformers 的编码-解码结构，对抽取拼接后的语句进行摘要生成；最后是基于 Prompt 的主题信息增强模块，该模块使用 Prompt 分别提取出整体、客户以及客服这三类对话各自的主体信息，并将主题信息嵌入到抽取模块与摘要生成模块的解码层当中，按当前语句的角色信息进行分别指导。

同时，为了应对摘要文本关键信息缺失的问题，我们认为需要提升在对话抽取的效果，尽量不遗漏关键语句，这样才能相对保证摘要生成的信息完整度。本文在模型训练时使用并改进了强化学习算法，联系起对话抽取模块与概要生成模块，提升了对话抽取模块的执行效果，在一定程度上提高了关键语句的抽取率，进而减少所生成摘要的信息丢失。




图 3-1 模型整体框架图

3.2 模型概览

在本节中，我们将简要地介绍模型框架以及模型的训练方法，在之后的章节中会对模型中各个部分以及具体方法进行细致的介绍，总体的模型如图 3-1 所示，该模型大体上可以分为三个模块：对话抽取模块，概要生成模块以及 Prompt 主题信息增强模块。

首先将当前输入对话表示为 $D = [u_0, u_1, u_2, \dots, u_n]$ ，其中 $u_i (0 \leq i \leq n)$ 表示整个对话当中的某一轮对话，由此将对话语句根据整体输入到对话抽取模块之中，通过编码操作，将所有对话各自转化为维度表示，然后使用 Point Network 来进行语句的选择提取。

然后便是将提取出的语句进行拼接输入到概要生成模块当中，首先使用微调之后的 BERT 模型进行编码操作，然后通过已训练好的 Transformer 解码模块进行解码输出，从而得到最终的摘要。

最后是基于 Prompt 的主题信息提取模块，首先使用 Prompt 进行分角色的主题信息抽取，具体分为对客服、客户以及全部对话。在获取对应的信息后，使用主题信息融合注意力机制，将信息融入到前两个模块的解码层当中。




图 3-2 对话抽取模块框架图

3.3 对话抽取模块

对话抽取模块是一个层次神经网络结构，首先学习对话当中的每一个句子的表示，之后再进一步置入指针网络当中进行句子的选取，具体模型如图 3-2 所示。

首先，该模型的输入句子组织形式如下， $u_i = [t_i^{cls}, r_i, e_{i1}, e_{i2}, \dots, e_{iN}]$ ，其中 u_i 表示整个对话 D 当中的第 i 轮对话， N 表示该轮对话所含有 N 个字符。而对于每一轮对话，首先置入了特殊的表示符 t_i^{cls} ，并添加上了角色的表示向量 r_i 用以区分当前句子的角色信息，而后的 e_{ij} 则是表示语句之中每一个词所对应的词向量。该模块的主要步骤如下：

(1) 对输入句子进行预处理，将“[CLS]”标记以及角色信息标记进行嵌入，分别放置到每一轮对话的句子之前。在完成基本的构建之后，对输入进行词嵌入处理，转化为对应的词向量，此处的词向量对应关系使用的是基于全词掩码的中文预训练模型 BERT-wwm。

(2) 将构建好的 u_i 输入到基于 Transformer 的编码层当中，对于整个输入序列进行编码操作，得到当前输入 u_i 对应的序列 $[m_i^{cls}, m_{i0}, \dots, m_{iN}]$ ，具体公式如下：

$$[m_i^{cls}, m_{i0}, \dots, m_{iN}] = \text{TFEnc}([e_i^{cls}, r_i, e_{i1}, \dots, e_{iN}]) \quad (3.1)$$

(3) 对于步骤(2)当中所得的结果,只需要取用其中的 m_i^{cls} , 参照 Devlin 的做法^[30]将进行整体输入编码后的特殊标记 “[CLS]” 来表示整一个句子, 将 m_i^{cls} 记为 m_i , 使用 m_i 表示第 i 轮对话的信息。因此可以将当前对话的表示转化为 $[m_1, m_2, \dots, m_M]$ (M 表示当前对话有 M 轮)。对于所获得的序列再一次输入到基于 Transformer 的编码层当中, 由此可得 $[h_1, h_2, \dots, h_M]$ 为进一步整体编码后的信息, 不仅包含当前句子的信息, 还包含了句子之间的关系。

$$[h_1, h_2, \dots, h_M] = \text{TFEnc}([m_1, m_2, \dots, m_M]) \quad (3.2)$$

(4) 根据 Vinyals^[31]所提出的指针网络, 可以进一步利用编码得到的信息来训练网络, 从而根据轮次进行迭代提取。

首先, 将编码信息输入到解码器当中, 其中 q_t 为当前 t 时刻所输入的部分解码序列, 如果在当前时刻, 第 i 轮对话 u_i 被选中了, 那么在 $t+1$ 时刻, 对话 u_i 所对应的编码向量 h_i 也会被加入到 q_t 当中成为新一轮的 q_{t+1} 。所得到的 t 时刻的解码状态信息可以表示为 z_t 。

此外, 为了让句子的提取有终止态, 此处人工添加了可训练的提取结束标识符 h_{EOF} , 该向量维度与其他对话表示信息相同, 当选取到该标识符时便停止句子的挑选, 同时本文也人工设置了所提取的句子的最大总长度 l_{max} , 当总长度超过这个阈值时, 便不再继续选取。

$$z_t = \text{TFDec}([h_1, h_2, \dots, h_M, h_{EOF}]; q_t) \quad (3.3)$$

(5) 根据 Chen^[32]所使用的句子提取指针网络所执行的策略, 对于在 t 时刻选取第 i 轮的对话 i_t , 选取到该句子的概率 a_i^t 可以表示为:

$$a_i^t = \begin{cases} V \tanh(W_1 h_i + W_2 z_t) & \text{if } i_t \neq i_k \quad \forall k < t \\ -\infty & \text{otherwise} \end{cases} \quad (3.4)$$

其中 V, W 都是可训练的参数信息, 上述公式同时避免了句子的重复选取。同时, 在最后将所得到的 a^t 输入到 Softmax 层当中, 可以得到 t 时刻选出的句子 i_t 。

$$P(i_t | i_1, \dots, i_{t-1}) = \text{softmax}(a^t) \quad (3.5)$$




图 3-3 摘要生成模块框架图

由此进行迭代选取，每一次选取出整个对话当中的一轮对话，直到选取到之前加入的提取结束标识符 h_{EOF} 为止，进而整理得到所有提取的句子的标签为 $[L_1, L_2, \dots, L_k]$ 。

3.4 摘要生成模块

该模块位承接于对话抽取模块之后，根据所抽取的句子标签 $[L_1, L_2, \dots, L_k]$ ，对输入信息进行重整，首先将这些标签按照对话顺序进行排序，再将各个标签对应的句子进行拼接操作，同时保留表示角色信息的标签 r_i ，并使用特殊的分隔符标签 “[SEP]” 来分隔各轮对话。整合出的文段可以表示为：

$$D_p = [t^{cls}, r_1, e_{11}, \dots, e_{1m_1}, t^{sep}, r_2, e_{21}, \dots, e_{2m_2}, t^{sep}, \dots, t^{sep}, r_k, e_{k1}, \dots, e_{km_k}]$$

D_p 为摘要生成模块的输入信息。该模块遵循标准的序列到序列 (Seq2Seq) 的模式，主要使用 Transformer 的编码-解码架构来实现输入语句到摘要的压缩生成，如图 3-3 所示，主要的步骤如下：

(1) 将 D_p 输入到预训练模型 BERT-wwm 当中，将 BERT 作为编码器进行基本的编码操作，将输入的文本转化为向量，为之后输入到解码层当中做准备。

(2) 然后将编码所得信息输入到基本的 Transformer 解码层当中，通过与数据集给出的标准摘要进行比对训练，最终在训练完毕之后可以自行根据输入生成摘要。




图 3-4 Prompt 提取主题信息模块图

3.5 主题信息增强模块

主题信息增强模块主要分为两部分，第一部分为基于 Prompt 的主题信息抽取模块，第二块为主题信息融合注意力机制。该模块尝试使用 Prompt 来获取语句之中的主题信息，其中采用分角色的方式来进行分别提取，并将所提取对应的主题信息分别融入到对话提取模块和摘要生成模块的解码层当中。

3.5.1 Prompt 提取主题信息模块

如图 3-4 所示，该部分的主要任务为：使用 Prompt 从对话语句当中提取出对应的主题信息。具体的步骤如下：

(1) 首先需要将原对话进行拼接构建，具体执行方法为，将所有的对话语句放置在一起，按顺序进行拼接，将原对话进行分角色的构建，最终构建出对话文档 $D_O = [t^{cls}, u_0, u_1, u_2, \dots, u_n]$ ，同时，再分别提取出只含客户语句的对话文档 D_C 和只含客服语句的对话文档 D_A 。

(2) 之后将这三个对话文档分别与预先设置好的 Prompt 进行拼接操作，具体形式为 $P_O = [D_O, \text{该, 对, 话, 的, 主, 题, 为, [MASK]}]$ ，其中“[MASK]”为特殊标签，用于获取当前对话文档的主题信息，根据此方式可以获得其他两种对话文档的输入形式 P_A 与 P_C 。

(3) 接下来，将 P_O 输入到预训练模型 BERT-wwm 当中进行编码操作，最后取出编码输出的“[MASK]”位置所对应的信息 t^O 作为之后所使用的主题信息，同理可以得到客服文档和客户文档的主题信息 t^A 与 t^C 。




图 3-5 主题信息融合注意力机制图

3.5.2 主题信息融合注意力机制

在该部分当中，我们将多角色的主题信息融入到 Transformer 的解码层当中，并参照注意力机制设计了主题信息融合注意力机制，具体如图 3-5 所示。

q_i 表示解码过程当中第 i 步的 query，而 x_j 表示由编码层当中输出的第 j 个元素，原本的注意力机制可以表示为：

$$\alpha_{ij}^q = \text{softmax} \left((q_i W_Q) (x_j W_K^q)^\top / \sqrt{d_h} \right) \quad (3.6)$$

$$\mu_i^q = \sum_j \alpha_{ij}^q (x_j W_V) \quad (3.7)$$

其中 W_Q, W_K^q, W_V 都是可训练的参数， d_h 是每个注意力头的维度信息，而 μ_i^q 则是融合了 query 与第 i 步解码信息的向量，在一般的解码过程中，每一步的融合状态会以先前已解码的序列为条件，其中可能会积累错误。因此，在这里本文额外使用全局主题信息和角色信息作为指导，通过平衡编码输出内容与多角色主题之间的相关性来帮助序列解码。此处的设计如下：

$$\alpha_j^t = \text{softmax} \left((\tau W_T) (x_j W_K^t)^\top / \sqrt{d_h} \right) \quad (3.8)$$

$$\mu^t = \sum_j \alpha_j^t (x_j W_V) \quad (3.9)$$

其中 τ 表示角色相关的主题信息表示, 如果当前所解码的 x_j 是源自于客户, 那么 $\tau = [t^O; t^C; 0]$; 同理, 如果当前所解码的 x_j 是源自于客服, 那么 $\tau = [t^O; 0; t^A]$ 。 $[\cdot; \cdot]$ 表示将向量连接在一起, 0 则表示零向量。

最后, 我们将上述两种注意力机制进行融合, 让当前的解码步骤同时考虑到主题信息以及当前的 query。具体公式如下所示:

$$p_i^{sel} = \sigma([q_i; \mu_i^q; \mu^t] \cdot W_P) \quad (3.10)$$

$$\alpha_{ij} = (1 - p_i^{sel}) \cdot \alpha_{ij}^q + p_i^{sel} \cdot \alpha_j^t \quad (3.11)$$

$$\mu_i = \sum_j \alpha_{ij} (x_j W_V) \quad (3.12)$$

其中 $p_i^{sel} \in (0, 1)$ 表示当前两种注意力所融合的比例。对于 x_j , 在对话抽取模块中表示为第 j 个句子的向量表示, 而在概要生成模块当中则表示第 j 个字符的向量表示, 因此实现了基于句子层面和字符层面的主题信息融合。

3.6 模型训练

由于该模型的对话提取模块所执行的提取操作是不可微的, 所以在进行训练的时候, 我们参照 Chen^[32]的做法, 使用了并改进了 SCST(self-critical sequence training)^[33]作为作为强化学习的策略梯度算法, 进而连接起对话抽取模块以及概要生成模块。

在实际实验过程当中, 训练主要分为两个阶段, 分别为模型预训练与正式训练部分。

(1) 首先是预训练部分, 对模型进行预训练是为了解决强化学习的冷启动问题, 如果不进行这一步骤的话将很难训练起模型。

对于对话抽取模块, 要训练模型挑选出含有较为关键信息的语句, 并丢弃相对不重要的语句。但是由于没有标准的关键句标签作为参考, 模型的训练将很难进行, 于是这里参照了 Nallapati^[34]的做法, 使用贪心策略来循环提取原对话当中的句子直到当前所




图 3-6 强化学习示意图

提取的句子所组合起来的文档与标准摘要的 ROUGE 值^[35]达到最大，之后便将这些句子标签作为标准的提取参照。

对于摘要生成模块，因为也需要较为标准的数据作为输入来训练，所以在预训练阶段所需要执行的任务便是将之前贪心提取的句子进行连接作为输入部分，参照标准摘要进行训练。

(2) 然后是正式训练部分，在本工作当中我们采用了 SCST 作为作为强化学习的策略梯度算法。具体策略为：在每一次进行提取训练的时候。会从对话抽取器得到两组对话，第一组对话 $\hat{y}$ 是使用贪心算法，直接选取出对话抽取阶段每一步当中概率最大的语句，而第二组对话 y^s 则是按照所给出的概率分布进行随机选取。之后将这两组对话都输入到摘要生成模块当中，各自产生对应的摘要并计算出 Rouge 值，将 Rouge 值作为训练的奖励，称为 $R(y^s)$ 与 $R(\hat{y})$ 。

在以往的模型当中，此处的 Rouge 值一般采用的 Rouge-L 的 F1 值，而在实际实验过程当中，本文对该指标进行改进，发现当采用 Rouge-1 的召回率作为奖励函数的时候，将会提升对话提取模块的效果，是的对话抽取更为全面，减少关键信息的缺失，进而提升摘要生成的质量。因此将抽取阶段的损失值 $\mathcal{L}_{ext}$ 设置为：

$$\mathcal{L}_{ext} = - (R(y^s) - R(\hat{y})) \log p(y^s) \quad (3.13)$$

通过对上述损失函数的梯度下降策略，对对话抽取模块行了优化。而对于概要生成模块，我们让每个解码步骤中的最大似然损失最小化，以执行一个标准的 seq2seq 学习

来生成摘要记为 $\mathcal{L}_{abs}$ 。

综上所述，在训练阶段最终的损失函数 $\mathcal{L}_S$ 可以表示为：

$$\mathcal{L}_S = \mathcal{L}_{ext} + \mathcal{L}_{abs} \quad (3.14)$$

3.7 伪代码展示

Algorithm 1: Prompt-based Topic-augmented Dialogue Summarizer

Input: Dialogue set D

Output: Dialogue summary S

```

1  $t_o, t_s, t_a = \text{Prompt-Topic-Extractor}(D)$  for  $u_i : D$  do
2    $m_i^{cls} = \text{Sentence-Encoder}(u_i);$ 
3    $M.append(m_i^{cls});$ 
4 end
5  $H = \text{Dialogue-Encoder}(M);$ 
6 while  $l_i \neq l_{EOF}$  do
7    $l_i = \text{Point-Network-Extractor}(H, t_o, t_s, t_a);$ 
8    $L.append(D[l_i]);$ 
9 end
10  $D_s = \text{Concatenation}(L);$ 
11  $E_s = \text{Abstraction-Encoder}(D_s);$ 
12  $S = \text{Abstraction-Decoder}(E_s, t_o, t_s, t_a);$ 
    
```

3.8 本章小结

在这一章节当中，我们首先介绍了本文的研究动机，然后概述了本文设计的基于 prompt 的主题信息增强客服对话摘要模型。在阐述完整体的框模型架之后，再根据模型组成进行各个模块的分解分析，详细讲述子模块当中的实现细节，然后还给出了模型的训练方法，以及本文在强化学习模块的上的改进。最后给出了本模型的伪代码，体现整体的执行流程。

4、模型训练与实验评价

4.1 数据集

本文所使用的公开数据集为 CSDS^[36], 该数据集为中文客服对话摘要数据集, 基于现实电商场景当中的客服与客户之间的对话, 并对原始数据进行了人工的挑选与精炼, 其中每一个对话实例都给按照对话轮次进行切分, 表现形式为当前对话者角色信息 (该数据集角色取客服与客户)、当前对话轮次以及对话语句, 且在每个实例的最后给出了人工总结的摘要。

选用该数据集的原因首先是因为该数据集的组织形式十分契合本文所研究的主题, 其次是因为当前公开的中文客服对话摘要数据集稀缺, 难以找到其他相关数据集。总的来说, 该数据集的特点有: 倾向使用轮数较多的对话, 以保证有足够的信息以及摘要难度; 对话主题种类繁多, 并且分布均匀, 符合本文所研究的主题信息增强的要求; 所有的对话语义完整, 不会从长对话当中截取一部分。此外, 该数据集的一条数据常常含有多个问答对, 并且在人工给出的摘要当中, 也遵循着客服客户一问一答的对应形式。这将有助于最终生成的摘要结果更加有逻辑性有条理, 同时能帮助模型总结的摘要更加完整清晰。

该数据集的基本信息如表 4-1 所示, 训练集有 9101 个对话实例, 验证集与测试集分别有 800 例。其中对于训练集而言, 每个对话实例的平均总长度上为 401, 对话轮数为 26, 此外, 在训练集当中每个实例平均问题与回答对数接近 2, 即表示在摘要当中客服与客户的问答平均对数为 2。

表 4-1 数据集设置

	# Dial.	Dial. Length	# Turns	# QA Pairs
Train	9101	401.08	26.00	1.98
Dev.	800	396.34	25.90	1.99
Test	800	387.10	25.11	1.90

4.2 模型设置

该模型所使用的预训练模型为中文 BERT-wwm, 该预训练模型使用中文维基进行训练, 并且相对于原本的 BERT, 它更改了原预训练阶段的训练样本生成策略, 它使用 Mask 标签替换一个完整的词而不是字词。使用该预训练模型完成了对话提取模块与概要生成模块的字层面编码。其中模型的具体细节设置如下:

(1) 对话抽取模块当中的编码阶段主要分为 2 部分, 分别为对输入句子进行编码的 Transformer 编码层, 以及对编码后取出的 "[CLS]" 标签进一步联合编码的 Transformer 编码层, 其层数分别设置为 3 层与 2 层。而对话抽取模块所使用的 Transformer 解码层层数则设置为 2 层。并且模型对于字与句统一编码的向量维度为 768。

(2) 摘要生成模块的编码器直接使用 BERT 模型, 包含 12 层 BertLayer, 而解码器则使用 Transformer 的解码器, 且解码层设置为 3 层。

(3) 主题信息抽取模块直接使用中文预训练 BERT-wwm, 使用 BERT 架构, 其中编码层同样包含 12 层 BertLayer。

在实际实验过程当中, 采用 mini-batch 的方法进行训练, 预训练使用了使用了 8w 步, 在正式训练时联合训练了 2w 步, 并且每 1k 步记录一次模型, 最终, 取出前三个在验证集上表现的最好的模型进行测试, 最后进行平均得到最终结果。

4.3 实验结果及其分析

在本节当中, 将具体列出本文所做的各个实验的评价指标结果, 并对比各模型的效果, 分析其中可能的原因。

4.3.1 评价指标

在列举实验结果之前, 首先需要说明的是本文所使用的评价指标, 对于对话文本摘要任务的生成质量评估, 本文使用的评判指标为 ROUGE^[35]和 BLEU^[37]。评价指标 ROUGE 利用系统生成的输出与预先给出的标准摘要进行比对, 主要思想是通过计算文本之间重叠的基本单元数目来评价系统摘要的质量, 主要有 ROUGE-1 和 ROUGE-2, 此外还比对了最长的子序列, 对应指标 ROUGE-L 来评估文本流畅性。而对于指标 BLEU, 我们最多使用 4-gram 的字节片段, 本文采用从 1-gram 到 4-gram 的累积分数。此外本实

验所有的指标都是对单个字符进行计算，从而避免中文分词的影响。

4.3.2 基线模型介绍

在该部分当中，我们使用 CSDS 数据集具体跑了以下几个基线模型，通过比对其效果来展现本文模型的有效性。

(1) SummaRuNNer^[34]: 该方法是一种有监督的提取总结方法，使用 RNN 对每个话语进行评分。然后根据评分来提取生成最终的摘要。

(2) BERT-EXT^[38]: 该方法与 SummaRuNNer 方法类似，不同之处是该模型使用的是微调后的预训练模型 BERT 来进行语句的评分。

(3) LexPageRank^[39]: 该方法通过 PageRank 算法对对话话语进行排序，并依次提取话语，直到摘要的长度达到极限。

(4) BERT-ABS^[38]: 该方法使用预训练模型 BERT 作为模型的编码器，然后使用基于 Transformer 的解码器来进行概要生成。

(5) TDS-SATM^[24]: 该方法所使用的主体部分同样也是主题信息增强的二阶段的对话摘要模型 (TDS)，与本文不同的是，该模型使用的是神经主题模型 (SATM) 来提取对话的主题信息。

4.3.3 实验结果展示分析

在该部分我们将实验结果分为以下五个部分进行分别展示分析：

(1) 首先是对于最终生成的摘要进行 ROUGE 与 BLEU 的评价指标测试，具体结果如表 4-2 所示。其中 TDS 模型表示的是不使用的主题信息增强模块的本文模型，只包含对话抽取与摘要生成模块，可以看到 TDS 模型的实验效果超过 BERT-ABS 等一众基线模型，在评价指标上平有较大的提升，说明在对话任务当中采取先进行对话抽取，再进行摘要生成这样的二阶段摘要模型相比于一般的抽取式模型或者是摘要生成式模型是切实有效的。

其次将本文所使用的主题抽取模块加入到 TDS 模型当中，可以看到 P-TDS 在 Rouge-1、Rouge-2 与 BLEU-L 这三个机器评价指标上分别提高了 2.38、0.88、0.65 个百分点，证明了将主题抽取模块在该模型当中是有效的，并且在最终生成结果上有促进效果。

再将本模型与使用类似的框架的 TDS-SATM 模型进行对比，可以发现在 Rouge-1 与 Rouge-2 这两个指标上分别提升了 1.82 与 0.16 个百分点，但在 Rouge-L 和 BLEU 这两个指标上结果有下降。但总体上可以看到结果上差距并不大，说明本模型相比于 TDS-SATM 模型的效果有所提升。

表 4-2 基线模型对比实验结果

模型	ROUGE-1(%)	ROUGE-2(%)	ROUGE-L(%)	BLEU(%)
SummaRuNNer	55.41	33.93	50.22	21.60
BERT-EXT	52.45	31.64	45.25	21.59
LexPageRank	47.94	23.36	38.07	13.48
BERT-ABS	46.64	27.81	39.53	24.59
TDS	55.20	35.29	48.89	23.73
TDS-SATM	55.76	36.01	49.60	24.22
P-TDS	57.58	36.17	49.54	24.11

(2) 第二部分我们将分析对话抽取模块的效果，如表 4-3 所示，本文选取了使用 TDS 模块的以下模型来进行参照对比，分别展示了对话选取的准确率，召回率以及 F1 值，其中的参考标签为之前人工构建的对话提取标签。

可以看到在对话抽取模块当中，精确度最高的是 TDS-SATM 模型，在提取句子的准确率上占优，其整体结果稍好于 TDS 模型。对于本文所使用的 P-TDS 模型，可以明显发现在召回率指标上有较大的提升，超过 TDS 模型 15.7 个百分点。且相较于 TDS-SATM 召回率提升了 22%，同时在最终的 F1 值上要高 3.93 个百分点。可以直观的感受，本文所实现的模型主要在对话抽取这个过程中起到了较大的作用，较大幅度提升关键句子的选取率，进而所抽取的句子将会进一步影响最终摘要的生成。

表 4-3 对话抽取模块结果表

模型	Precision(%)	Recall(%)	F1(%)
TDS	67.59	57.34	62.04
TDS-SATM	67.76	59.63	63.43
P-TDS	62.49	73.04	67.36

(3) 第三部分将对于之前文中所提到的改进强化学习的奖励函数的部分进行对比与分析, 其中 P-TDS* 是指仍然使用 Rouge-L 的 F1 作为奖励函数的模型实验, 如表 4-4 与表 4-5 所示, 对强化学习模块进行改进后, 对话抽取的模块的执行性能相较于未改变训练方法的模型在找回率上提升了 2.53 个百分点, 在 F1 值上则提升了 0.65 个百分点。同时在最终的摘要生成评价指标上也均有略微提升, 说明对强化学习这一部分所做的更改确实起到了一定的作用, 提升了对话抽取这一模块的效果。

表 4-4 摘要结果对比实验结果

模型	ROUGE-1(%)	ROUGE-2(%)	ROUGE-L(%)	BLEU(%)
P-TDS*	57.49	36.18	49.37	23.39
P-TDS	57.58	36.17	49.54	24.11

表 4-5 对话抽取模块结果表

模型	Precision(%)	Recall(%)	F1(%)
P-TDS*	63.30	70.51	66.71
P-TDS	62.49	73.04	67.36

(4) 根据以往研究经验, 使用不同的 Prompt 将会产生不同的影响与实验结果, 所以接下来我们将使用不同的 Prompt 来进行信息提取, 以便验证比对效果。

表 4-6 更改 Prompt 对比结果表

	Rouge-1	Rouge-2	Rouge-L	BLEU
[X]该对话的主题为[Z]	57.49	36.18	49.37	23.39
[X]主题为[Z]	57.92	36.55	49.84	24.04
[X] [Z]	57.10	36.01	49.41	23.24

结果如表 4-6 所示，该图当中的“[X]”对应的是汇总的对话信息，而“[Z]”对应的则是本实验中添加的“[MASK]”特殊标识符，用于表示提取的主题信息。可以看到这三种构建方式所相差的效果并不多，但是相对合理的模板构造将有助于摘要生成，可以看到模板“[X] [Z]”对应的效果略逊于前两种模板。

(5) 最后我们对于 P-TDS 模型中的主题信息融合注意力机制进行了进一步的消融实验分析，之前实验所用到的注意力模块分别提取了全部语句，客服语句与客户语句的主题信息，并在具体的主题融入模块当中按说话者进行分角色的指导。于是这里分别对客服与客户主题信息进行削除，来观察最终的实验效果，具体结果如表 4-7 所示。

可以看到 P-TDS 模型在削除客服和客户信息之后的结果在各个指标上都略有下降，该结果说明特定于角色信息主题信息抽取是有益的，并且至少应该指定一个发言者，以使角色内容可区分。

表 4-7 消融实验结果表

Methods	ROUGE-1(%)	ROUGE-2(%)	ROUGE-L(%)	BLEU(%)
P-TDS	57.49	36.18	49.37	23.39
(w/o)Cust	56.45	36.27	48.73	23.24
(w/o)Agent	56.34	36.02	48.98	23.18
(w/o)Agent,Cust	56.31	36.05	48.75	23.51

4.4 案例分析

我们对测试集所生成的结果进行了进一步的人工检查与分析，如图 4-1 所示，具体展示了其中的一个实例结果。该图左半部分为一个完整的客服与客户之间的对话，其中图的右上方给出了该例的标准摘要（Gold Summary）以及我们在实验当中自行构建的

ORIGIN : (0) 【客户】 请选择咨询订单 (1) 【客服】 有什么问题我可以帮您处理或解决呢? (2) 【客户】 你好,我昨天的订单退款,到了吗 (3) 【客服】 您好辛苦您提供一下订单号呢 (4) 【客户】 [数字] (5) 【客服】 您再核对一下订单号呢这个不对呢 (6) 【客户】 [订单编号] (7) 【客服】 您好这边看到退款已经完成了呢,直接回复您白条额度 (8) 【客服】 到账周期一般是[数字]个工作日,您注意看一下呢 (9) 【客户】 你好在吗 (10) 【客服】 在的呢 (11) 【客服】 您能看到我回复的消息吗~ (12) 【客户】 我把单号重发了一遍 (13) 【客服】 您这边看到我回复的消息吗~ (14) 【客户】 能啊 (15) 【客服】 您好看到退款已经完成了,直接回复您的白条额度的到账周期一般是[数字]个工作日,您注意看一下 (16) 【客户】 但我要查的单号你还没回复呢 (17) 【客服】 [订单编号]是这个订单的退款嘛 (18) 【客户】 那我现在能照昨天的金额再买吗 (19) 【客服】 您昨天有[金额]元的白条支付有礼退款之后是没有了的哦 (20) 【客户】 退了就没有了嘛 (21) 【客服】 嗯呢 (22) 【客服】 这个是无法恢复的 (23) 【客户】 好吧谢谢 (24) 【客服】 不客气的请问还有其他还可以帮到您的吗? (25) 【客户】 没事了谢谢,那我的钱已经到账了是吧 (26) 【客服】 嗯嗯最迟是明天到账的,您可以看一下白条额度有没有恢复! (27) 【客户】 好 (28) 【客服】 还辛苦您给小妹打个评价呢~点击表情栏旁边的“+”哦。 (29) 【客服】 感谢您对京东的支持,祝您生活愉快,再见!	GOLD SUMMARY : 用户询问订单退款是否到账。客服回复退款已经完成时直接恢复白条额度。 用户询问是否可以再按照之前的金额购买。客服表示之前的白条支付有礼退款后不再保有。 EXT_GOLD: [0,2,15,18,19,22,24,28] BERT-ABS 用户询问昨天的订单退款是否到了。客服回答看到退款已经完成,直接回复白条额度的到账周期一般是[数字]个工作日。 用户要求查询订单号,询问是否能重新购买,以及退款金额是否已经到账。客户回答最迟是明天到账的白条支付有无法恢复。 BERT-EXT 用户:你好,我昨天的订单退款。到了吗。 客服:这个是无法恢复的。客服:您好这边看到退款已经完成了呢,是直接回复您的白条额度的到账周期一般是[数字]个工作日,您注意看一下呢 P-TDS: 用户询问订单退款是否到账。客服回复退款已经完成,直接回复白条额度的问题。 用户询问客服能否查询白条额度。客服回复最迟是[数字]个工作日。 SUMMARY bleu & rouge-f 1/2/l: 0.4166 & 0.6087/0.4561/0.5870 EXT_PRED: [0,2,7,8,11,15,19,24,26,28] EXT_SCORE P/R/F1: 0.6000/0.7500/0.6667 TDS: 用户询问昨天的订单退款是否到账。客服回复退款已经完成,到账周期一般是[数字]个工作日。 用户询问退款是否到账。客服回答最迟是明天到账,可以看一下白条额度。 SUMMARY bleu & rouge-f 1/2/l: 0.4013 & 0.5657/0.4262/0.4444 EXT_PRED: [2,7,8,15,16,19,24,26,28] EXT_SCORE P/R/F1: 0.5556/0.6250/0.5882
---	---

图 4-1 实例分析

参考抽取语句标签 (Gold Extraction Labels), 同时在该图当中, 我们还分别给出了模型 BERT-ABS 以及模型 BERT-EXT 所生成的摘要。如图左下角所示, 具体给出了本实验所测试使用的 TDS 模型与 P-TDS 的评价信息与对话抽取标签。

实例当中标红的便是 P-TDS 模型在对话抽取模块当中所选取的句子, 该例当中 P-TDS 的抽取效果好于 TDS 模型, 相对于参考的对话提取标签, 该例已选取了其中的四分之三, 并且在最终的结果生成上, 其各个评价指标均占优势。可以看到 P-TDS 所生成的摘要第一句为“用户询问订单退款是否到账。客服回复退款已经完成, 直接回复白条额度的问题。”, 该句语义与内容已十分接近参考摘要, 并且按照客服与客户的一问一答的形式进行, 最终生成了较为清晰简洁的对话摘要。但是其不足之处在于, 相较于标准的参考摘要, 摘要文本的第二句: “用户询问客服能否查询白条额度。客服回复最迟是[数字]个工作日。”, 即使在原对话中选取到了对应的句子, 在最后的摘要生成时仍没有很好的表述出来, 造成了信息的缺失, 在摘要的生成方面有待改进。

4.5 本章小结

在这一章节当中我们首先介绍了本实验使用的 CSDS 数据集的基本信息, 然后讲述了该模型的参数设置, 最后放出了本模型与相关模型的实验结果, 并相应做了消融实验进行具体结果分析, 结果表明我们提出的主题信息增强的客服对话摘要模型以及强化学

习的改进方法是有效的。

5、总结与展望

5.1 工作总结

近年来随着深度学习技术与自然语言处理技术的不断发展,智能客服、文本摘要等应用正逐步走入人们的生活当中。其中,文本摘要作为自然语言处理领域当中的重要应用得到了学术界与工业界的广泛关注。而客服对话摘要则是以客服与客户之间的对话作为摘要材料的文本摘要任务,通常应用于客户服务系统中。对话摘要通过自动构建对话摘要来提高整体服务效率,帮助客服在后续服务当中快速获取客户所需信息,从而避免了无用信息的重复读取,有效减少人工时间耗费。本文根据此类应用的迫切需求,在客服对话摘要任务上进行研究。考虑到当前文本摘要的方法并不能很好的应用于对话摘要,且传统摘要中容易造成对话中角色信息遗漏的缺失。本文参照先前研究者的工作,使用中文客服对话摘要数据集,提出了基于 Prompt 的主题信息增强对话摘要模型。

该模型的主要组成部分主要分为三部分,首先是对话抽取模块之中,该模块通过编码操作,将所有对话各自转化为维度表示,并使用 Point Network 来进行语句的循环选择提取。然后是概要生成模型,该模块将提取出的语句进行拼接并进行序列到序列的生成,该模块使用微调之后的 BERT 模型进行编码操作,然后通过 Transformer 解码模块进行解码输出,从而得到最终的摘要。最后是基于 Prompt 的主题信息提取模块,该模块使用 Prompt 进行分角色的主题信息抽取,具体分为对客服、客户以及全部对话。在获取对应的信息后,使用主题信息融合注意力机制,将信息融入到前两个模块的解码层当中,对这两个模块分别进行指导操作。

最终在 CSDS 数据集上进行了测试,测试指标 ROUGE 与 BLUE 相较于其他基线模型均有较为明显的提升。

5.2 未来工作

尽管本文在客服对话摘要模型上提出了使用 Prompt 来提取语句当中隐含的主题信息并将信息加入到客服对话摘要模型当中的策略,一定程度上提升了摘要模型的效果。但是我们在研究过程中发现仍然有许多值得继续深入研究的点,总体来看,主要可以分为以下几个点:

(1) Prompt 作为近几年以来的新兴研究热点收到了广泛的关注,并且被应用到了各个自然语言处理任务当中,但是由于本文所使用的 Prompt 方法仍较为基础,并且整体而言是一个较为黑箱的方法,在具体实现过程当中,对于其生成的信息还是难以把握。

(2) 对于模板的设计方面,本文所采用的是人工构建的方式,较为费时费力,且验证过程较慢。在已有的方法当中,已经有不少自动生成模板的策略方法,因此,在未来的工作当中可以尝试由计算机自动生成模板,并可以尝试使用连续的模板而不是本实验的离散模板来进行进一步的实验。

(3) 同时,在生成的效果方面,有一些摘要结果之间的逻辑性并不强,有时候可能会造成回答语句的杂糅以及语义方面的错误,未来的工作可以着重于句子之间的连贯性等问题。除此之外,在摘要的生成方面可以向更标准化、规范化的方向做努力,让生成的摘要更容易汇报与理解。

参考文献

- [1] 刘挺, 李维刚, 张宇. 复述技术研究综述[J]. 中文信息学报, 2006(20): 27-34.
- [2] FENG X, FENG X, QIN B. A Survey on Dialogue Summarization: Recent Advances and New Frontiers[J]., 2021.
- [3] GUREVYCH I, STRUBE M. Semantic similarity applied to spoken dialogue summarization[C]// COLING 2004: Proceedings of the 20th International Conference on Computational Linguistics. [S.l. : s.n.], 2004: 764-770.
- [4] NALLAPATIR, XIANG B, ZHOU B. Sequence-to-Sequence RNNs for Text Summarization[J]. CoRR, 2016, abs/1602.06023. eprint: 1602.06023.
- [5] LIU P, YUAN W, FU J, et al. Pre-train, prompt, and predict: A systematic survey of prompting methods in natural language processing[J]. ArXiv preprint arXiv:2107.13586, 2021.
- [6] HE J, KRYŚCIŃSKI W, MCCANN B, et al. Ctrlsum: Towards generic controllable text summarization[J]. ArXiv preprint arXiv:2012.04281, 2020.
- [7] YIN W, HAY J, ROTH D. Benchmarking zero-shot text classification: Datasets, evaluation and entailment approach[J]. ArXiv preprint arXiv:1909.00161, 2019.
- [8] BANKO M, MITTAL V O, WITBROCK M J. Headline generation based on statistical translation[C]// Proceedings of the 38th Annual Meeting of the Association for Computational Linguistics. [S.l. : s.n.], 2000: 318-325.
- [9] NARAYAN S, COHEN S B, LAPATA M. Don't give me the details, just the summary! topic-aware convolutional neural networks for extreme summarization[J]. ArXiv preprint arXiv:1808.08745, 2018.
- [10] SOOD A, MOHAMED T P, VARMA V. Topic-focused summarization of chat conversations[C]// European Conference on Information Retrieval. [S.l. : s.n.], 2013: 800-803.
- [11] XIE S, LIU Y, LIN H. Evaluating the effectiveness of features and sampling in extractive meeting summarization[C]// 2008 IEEE Spoken Language Technology Workshop. [S.l. : s.n.], 2008: 157-160.
- [12] OYA T, MEHDAD Y, CARENINI G, et al. A template-based abstractive meeting summarization: Leveraging summary and source text relationships[C]// Proceedings of the 8th International Natural Language Generation Conference (INLG). [S.l. : s.n.], 2014: 45-53.

- [13] LIU C, WANG P, XU J, et al. Automatic dialogue summary generation for customer service[C]// Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining. [S.l. : s.n.], 2019: 1957-1965.
- [14] LI M, ZHANG L, RADKE R J, et al. Keep meeting summaries on topic: Abstractive multi-modal meeting summarization[C]// 57th Conference of the Association for Computational Linguistics. [S.l. : s.n.], 2019.
- [15] SHANG G, DING W, ZHANG Z, et al. Unsupervised abstractive meeting summarization with multi-sentence compression and budgeted submodular maximization[J]. ArXiv preprint arXiv:1805.05271, 2018.
- [16] PAN H, ZHOU J, ZHAO Z, et al. Dial2desc: end-to-end dialogue description generation[J]. ArXiv preprint arXiv:1811.00185, 2018.
- [17] BANERJEE S, MITRA P, SUGIYAMA K. Multi-document abstractive summarization using ilp based multi-sentence compression[C]// Twenty-Fourth International Joint Conference on Artificial Intelligence. [S.l. : s.n.], 2015.
- [18] ZOU Y, LIN J, ZHAO L, et al. Unsupervised summarization for chat logs with topic-oriented ranking and context-aware auto-encoders[J]. ArXiv preprint arXiv:2012.07300, 2020.
- [19] YUAN L, YU Z. Abstractive dialog summarization with semantic scaffolds[J]. ArXiv preprint arXiv:1910.00825, 2019.
- [20] ZHANG X, ZHANG R, ZAHEER M, et al. Unsupervised abstractive dialogue summarization for tete-a-tetes[J]. ArXiv preprint arXiv:2009.06851, 2020.
- [21] MIAO Y, GREFENSTETTE E, BLUNSOM P. Discovering discrete latent topics with neural variational inference[C]// International Conference on Machine Learning. [S.l. : s.n.], 2017: 2410-2419.
- [22] WANG L, YAO J, TAO Y, et al. A reinforced topic-aware convolutional sequence-to-sequence model for abstractive text summarization[J]. ArXiv preprint arXiv:1805.03616, 2018.
- [23] FU X, WANG J, ZHANG J, et al. Document summarization with vhtm: Variational hierarchical topic-aware mechanism[C]// Proceedings of the AAAI Conference on Artificial Intelligence: vol. 34: 05. [S.l. : s.n.], 2020: 7740-7747.
- [24] ZOU Y, ZHAO L, KANG Y, et al. Topic-oriented spoken dialogue summarization for customer service with saliency-aware topic modeling[J]. ArXiv preprint arXiv:2012.07311, 2020.

- [25] CAO Z, LI W, LI S, et al. Retrieve, rerank and rewrite: Soft template based neural summarization[C] // Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). [S.l. : s.n.], 2018: 152-161.
- [26] LIU L, UTIYAMA M, FINCH A, et al. Neural machine translation with supervised attention[J]. ArXiv preprint arXiv:1609.04186, 2016.
- [27] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need[J]. Advances in neural information processing systems, 2017, 30.
- [28] MIKOLOV T, CHEN K, CORRADO G, et al. Efficient estimation of word representations in vector space[J]. ArXiv preprint arXiv:1301.3781, 2013.
- [29] SARZYNSKA-WAWER J, WAWER A, PAWLAK A, et al. Detecting formal thought disorder by deep contextualized word representations[J]. Psychiatry Research, 2021, 304: 114135.
- [30] DEVLIN J, CHANG M W, LEE K, et al. Bert: Pre-training of deep bidirectional transformers for language understanding[J]. ArXiv preprint arXiv:1810.04805, 2018.
- [31] VINYALS O, FORTUNATO M, JAITLEY N. Pointer networks[J]. Advances in neural information processing systems, 2015, 28.
- [32] CHEN Y C, BANSAL M. Fast abstractive summarization with reinforce-selected sentence rewriting[J]. ArXiv preprint arXiv:1805.11080, 2018.
- [33] RENNIE S J, MARCHERET E, MROUEH Y, et al. Self-critical sequence training for image captioning[C] // Proceedings of the IEEE conference on computer vision and pattern recognition. [S.l. : s.n.], 2017: 7008-7024.
- [34] NALLAPATI R, ZHAI F, ZHOU B. Summarunner: A recurrent neural network based sequence model for extractive summarization of documents[C] // Thirty-first AAAI conference on artificial intelligence. [S.l. : s.n.], 2017.
- [35] LIN C Y. Rouge: A package for automatic evaluation of summaries[C] // Text summarization branches out. [S.l. : s.n.], 2004: 74-81.
- [36] LIN H, MA L, ZHU J, et al. CSDS: A Fine-Grained Chinese Dataset for Customer Service Dialogue Summarization[J]. ArXiv preprint arXiv:2108.13139, 2021.
- [37] PAPINENI K, ROUKOS S, WARD T, et al. Bleu: a method for automatic evaluation of machine translation[C] // Proceedings of the 40th annual meeting of the Association for Computational Linguistics. [S.l. : s.n.], 2002: 311-318.

- [38] LIU Y, LAPATA M. Text summarization with pretrained encoders[J]. ArXiv preprint arXiv:1908.08345, 2019.
- [39] ERKAN G, RADEV D. Lexpagerank: Prestige in multi-document text summarization[C]// Proceedings of the 2004 Conference on Empirical Methods in Natural Language Processing. [S.l. : s.n.], 2004: 365-371.

致谢

时光荏苒，转眼之间就到了本科毕业的时候了。在华东师范大学，我度过了快乐而又充实的四年时光，我真真切切地感受到了“爱在华师大”，在校园当中漫步，在教室里学习，在食堂里吃饭，我感受到的是华师大每一处的温度。在计算机每一位老师都是那么的和蔼可亲。在华师大的校园里，每一次感动都值得回忆，每一份回忆都值得珍藏。

值此论文完成之际，我想要感谢为本论文付出的每一个人。首先，特别要感谢的是我的论文导师杨老师。无论是在实验还是论文的写作方面，杨老师都对我遇到的困难与疑惑进行耐心细致的指导与解答，并且为我提供指明了方向，杨老师为本篇文章付出了相当多的精力和心血。再次由衷地感谢杨老师为我个人和为本文所付出的一切；其次，本篇论文的完成也离不开实验室中的师兄师姐，他们在本文的实验上给了我莫大的助，在我遇到困惑的时候，谢谢你们我无私地分享实验中的宝贵经验，同时你们地鼓励让我有信心完成本文的所有的工作；最后要感谢的是我的家人，没有你们一如既往的对我的信任，支持和理解，就没有我的今天。

青春的六月阳光灿烂，但也免不了离别的伤感。回顾这几年的时光，在感慨光阴飞逝的同时，我还想要向那些在我学习生活中给与过无私帮助的人表达我最衷心的感谢与祝福，谢谢你们的付出，包括所有的任课老师们，所有的同学们，校医院的医生们，食堂的叔叔阿姨们，还有校园里的各位工作人员等等，是你们所有人无私的辛苦付出筑起了华师大的温度。在华师大生活的点点滴滴，或是欢乐亦或是悲伤困苦我都会珍藏在心，这是我们大家的财富，这是我们一同创造的故事。最后，由衷地感谢为评审本文而认真工作的老师们！